Submission

Membangun Proyek Machine Learning

Pengantar Kriteria Utama Ketentuan Penilaian Tips and Trick Ketentuan Berkas Submission

Submission ini mencakup dua tahap utama, yaitu **Clustering** dan **Klasifikasi**, dengan kriteria serta urutan kerja sebagai berikut.

> Disarankan menggunakan scikit-learn versi 1.7.0 agar tidak terjadi conflict ketika pemeriksaan.

Kriteria 1: Memuat Dataset dan Melakukan Exploratory Data Analysis (EDA)

- Menampilkan dataset menggunakan function `head()`.
- Menampilkan informasi dataset dengan `info()`.
- Menampilkan statistik deskriptif dataset dengan menjalankan `describe()` untuk mendapatkan ringkasan data.

Reject (0 pts)

- Tidak menampilkan dataset menggunakan function `head()`.
- Tidak menampilkan informasi dataset dengan `info()`.
- Tidak menampilkan statistik deskriptif dataset dengan menjalankan `describe()` untuk mendapatkan ringkasan data.
- Cell code tidak memiliki output pada kode yang seharusnya menampilkan output atau mengalami error.

Basic (2 pts)

- Menampilkan dataset menggunakan function `head()`.
- Menampilkan informasi dataset dengan `info()`.
- Menampilkan statistik deskriptif dataset dengan menjalankan `describe()` untuk mendapatkan ringkasan data.

Skilled (3 pts)

- Semua ketentuan pada Basic terpenuhi.
- Menampilkan matriks korelasi.
- Menampilkan histogram untuk semua kolom dalam dataset, baik itu bertipe numerik maupun kategorikal.

Advanced (4 pts)

- Semua ketentuan pada Skilled terpenuhi.
- Visualisasi yang dilakukan tidak memiliki label yang overlap.

Fig 3. Visualisasi yang Baik dan Informatif 1

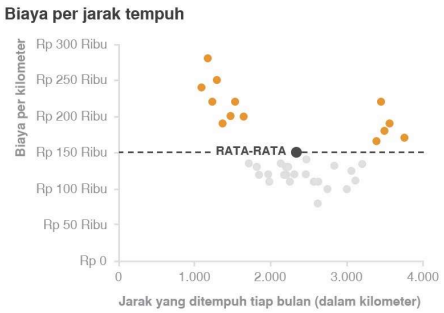

Fig 4. Visualisasi yang Baik dan Informatif 2

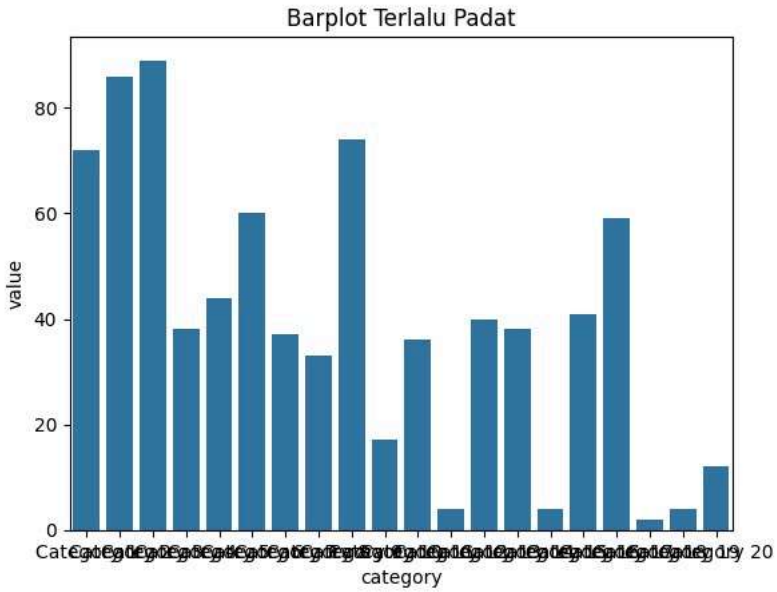

Fig 5. Visualisasi yang Tidak Baik dimana Label saling tumpang tindih

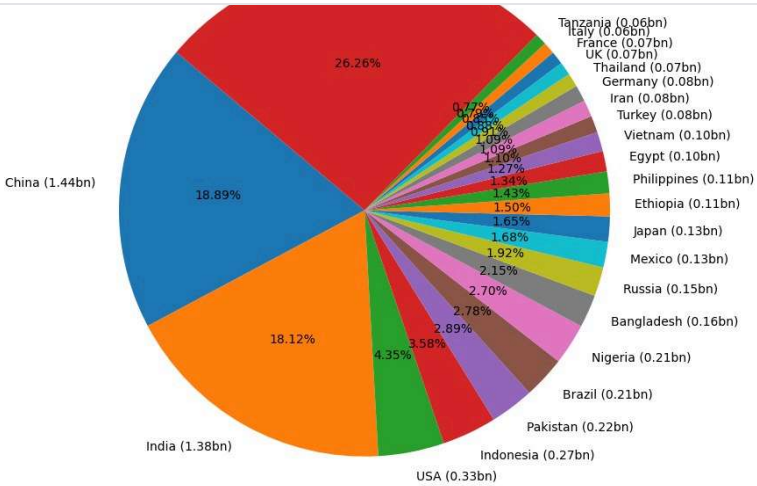

Fig 6. Visualisasi yang Kurang Informatif

Kriteria 2: Pembersihan dan Pra Pemrosesan Data

- Mengecek dataset menggunakan `isnull().sum()` dan `duplicated().sum()`.
- Menangani data yang hilang menggunakan `dropna()`.
- Menghapus data duplikat menggunakan `drop_duplicates()`.
- Melakukan drop pada kolom yang memiliki keterangan ID, Address, dan Date seperti TransactionID, AccountID, DeviceID, IPAddress, MerchantID, dan TransactionDate.
- Melakukan feature encoding menggunakan `LabelEncoder()` untuk fitur kategorikal.

Reject (0 pts)

- Tidak mengecek dataset menggunakan `isnull().sum()` dan `duplicated().sum()`.
- Tidak menangani data yang hilang menggunakan `dropna()`.
- Tidak menghapus data duplikat menggunakan `drop_duplicates()`.
- Melakukan drop pada kolom yang memiliki keterangan ID, Address, dan Date.
- Tidak melakukan feature encoding menggunakan `LabelEncoder()` untuk fitur kategorikal.

Basic (2 pts)

- Mengecek dataset menggunakan `isnull().sum()` dan `duplicated().sum()`.
- Menangani data yang hilang menggunakan `dropna()`.
- Menghapus data duplikat menggunakan `drop_duplicates()`.
- Melakukan drop pada kolom yang memiliki keterangan ID, Address, dan Date seperti TransactionID, AccountID, DeviceID, IPAddress, MerchantID, dan TransactionDate.
- Melakukan feature encoding menggunakan `LabelEncoder()` untuk fitur kategorikal.

Skilled (3 pts)

- Semua ketentuan pada kategori Basic terpenuhi.
- Melakukan Handling Outlier menggunakan metode drop.

Advanced (4 pts)

- Semua ketentuan pada kategori Skilled terpenuhi.
- Melakukan *binning* data berdasarkan kondisi rentang nilai pada fitur numerik, lakukan pada satu sampai dua fitur numerik. Silahkan lakukan encode hasil *binning* tersebut menggunakan LabelEncoder.

Kriteria 3: Membangun Model Clustering

- Menggunakan dataset yang sudah dilakukan preprocessing.
- Melakukan visualisasi Elbow Method untuk menentukan jumlah cluster terbaik menggunakan `KElbowVisualizer()`.
- Menggunakan algoritma K-Means Clustering dengan `sklearn.cluster.KMeans()`.
- Menjalankan cell code `joblib.dump()` dengan nama model_clustering agar reviewer dapat secara otomatis menilai evaluasi model anda.

Reject (0 pts)

- Tidak menggunakan dataset yang sudah dilakukan preprocessing.
- Tidak melakukan visualisasi Elbow Method menggunakan `KElbowVisualizer()`.
- Tidak menggunakan algoritma K-Means Clustering.
- Tidak menjalankan cell code `joblib.dump()` dengan nama model_clustering.

Basic (2 pts)

- Melakukan visualisasi Elbow Method menggunakan `KElbowVisualizer()`.
- Menggunakan algoritma K-Means Clustering
- Menjalankan cell code `joblib.dump()` dengan nama model_clustering.

Skilled (3 pts)

- Semua ketentuan pada kategori Basic terpenuhi.
- Menghitung dan menampilkan nilai Silhouette Score.
- Membuat visualisasi hasil clustering

Advanced (4 pts)

- Semua ketentuan pada kategori Skilled terpenuhi.
- Membangun model menggunakan PCA.
- Simpan model PCA sebagai perbandingan dengan menjalankan cell code ini joblib.dump(model,"PCA_model_clustering.h5").

- Menampilkan dan menuliskan analisis deskriptif minimal mean, min, atau max (sangat direkomendasikan menuliskan semuanya) untuk fitur numerik.
- Menjelaskan karakteristik tiap cluster berdasarkan hasil proses agregasi.
- Mengekspor data training dari proses preprocessing beserta data hasil clustering dan berikan nama untuk kolom tersebut yaitu **Target**.

Berikut adalah analisis karakteristik untuk setiap cluster yang dihasilkan dari model KMeans.

1. **Cluster 1**:
   - **Rata-rata Annual Income (k$):** 48,260
   - **Rata-rata Spending Score (1-100):** 56.48
   - **Analisis:** Cluster ini mencakup pelanggan dengan pendapatan tahunan menengah dan tingkat pengeluaran yang cukup tinggi. Pelanggan dalam cluster ini cenderung memiliki daya beli yang moderat dan mereka lebih cenderung untuk membelanjakan sebagian besar pendapatan mereka.
2. **Cluster 2**:
   - **Rata-rata Annual Income (k$):** 86,540
   - **Rata-rata Spending Score (1-100):** 82.13
   - **Analisis:** Cluster ini menunjukkan pelanggan dengan pendapatan tahunan tinggi dan pengeluaran yang sangat tinggi. Pelanggan di cluster ini merupakan kelompok premium dengan daya beli yang kuat dan cenderung mengeluarkan uang dalam jumlah besar untuk produk atau layanan.
3. **Cluster 3**:
   - **Rata-rata Annual Income (k$):** 87,000
   - **Rata-rata Spending Score (1-100):** 18.63
   - **Analisis:** Cluster ini terdiri dari pelanggan dengan pendapatan tahunan yang tinggi tetapi pengeluaran yang rendah. Mereka mungkin memiliki kapasitas finansial yang baik namun tidak terlalu aktif dalam berbelanja. Ini bisa menunjukkan bahwa mereka lebih selektif dalam pengeluaran mereka atau mungkin lebih cenderung untuk menyimpan uang.

Reject (0 pts)

- Tidak menjelaskan karakteristik tiap cluster berdasarkan rentangnya.
- Tidak mengekspor data training dari proses preprocessing beserta data hasil clustering dan tidak mengatur nama untuk kolom tersebut yaitu **Target**.

Basic (2 pts)

- Menampilkan dan menuliskan analisis deskriptif minimal mean, min, atau max (sangat direkomendasikan menuliskan semuanya) untuk fitur numerik.
- Menjelaskan karakteristik tiap cluster berdasarkan hasil proses agregasi.
- Mengekspor data training dari proses preprocessing beserta data hasil clustering dan berikan nama untuk kolom tersebut yaitu **Target**.

Skilled (3 pts)

- Semua ketentuan pada kategori Basic terpenuhi.
- Mengembalikan data yang telah di encode dan *scale* dengan menggunakan metode `inverse_transform()` .
- Menampilkan dan menuliskan analisis deskriptif pada kedua jenis fitur
  - Numerik: minimal mean, min, atau max (sangat direkomendasikan menuliskan semuanya).
  - Kategorikal: minimal salah satu (sangat direkomendasikan menuliskan semuanya).
- Menjelaskan karakteristik tiap cluster berdasarkan hasil proses agregasi.

Advanced (4 pts)

- Semua ketentuan pada kategori Skilled terpenuhi.
- Mengintegrasikan kembali data yang telah di-inverse dengan hasil cluster(kolom target).
- Menyimpan data hasil inverse dan kolom Target kedalam file **data_clustering_inverse.csv**

- Menggunakan `train_test_split()` untuk melakukan pembagian dataset.
- Membangun model dengan algoritma Decision Tree.
- Menjalankan cell code `joblib.dump()` dengan nama decision_tree_model.h5 agar reviewer dapat secara otomatis menilai evaluasi model anda.

Rejected (0 pts)

- Tidak menggunakan penamaan terformat pada target dari dataset yaitu Target.
- Tidak menggunakan `train_test_split()` untuk melakukan pembagian dataset.
- Tidak membangun model dengan algoritma Decision Tree.
- Tidak menjalankan cell code `joblib.dump()` dengan nama decision_tree_model.h5.

Basic (2 pts)

- Menggunakan penamaan terformat pada target dari dataset hasil clustering yaitu Target.
  - Apabila menerapkan kriteria advanced di kriteria 4, gunakan data_clustering_inverse.csv
- Menggunakan `train_test_split()` untuk melakukan pembagian dataset.
- Membangun model dengan algoritma Decision Tree.
- Menjalankan cell code `joblib.dump()` dengan nama decision_tree_model.h5

Skilled (3 pts)

- Semua ketentuan pada kategori Basic terpenuhi.
- Mencoba setidaknya satu algoritma klasifikasi selain Decision Tree.
- Menampilkan hasil evaluasi akurasi, presisi, recall, dan F1-Score pada seluruh algoritma yang sudah dibuat.
- Menjalankan cell code `joblib.dump()` dengan nama explore_<Nama Algoritma>_classification.

Advanced (4 Poin)

- Semua ketentuan pada kategori Skilled terpenuhi.
- Melakukan hyperparameter tuning pada salah satu model klasifikasi yang dibuat.
- Menjalankan cell code `joblib.dump()` dengan nama tuning_classification.